

TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN



ĐỒ ÁN NHẬP MÔN

HỌC MÁY

Người hướng dẫn: **PGS.TS LÊ ANH CƯỜNG**

Người thực hiện: **NGUYỄN KHẮC ANH TÀI – 52100306**

Khoá : 25

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2023

TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN



ĐỒ ÁN NHẬP MÔN

HỌC MÁY

Người hướng dẫn: **PGS.TS LÊ ANH CƯỜNG**

Người thực hiện: **NGUYỄN KHẮC ANH TÀI – 52100306**

Khoá : 25

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2023

LỜI CẢM ƠN

Để hoàn thành bài báo cáo này, chúng em xin cảm ơn đến PGS.TS Lê Anh Cường đã hướng dẫn cho em đi từ những cái cơ bản nhất của môn Nhập Môn Học Máy để em có thể có đủ kiến thức hoàn thành bài báo cáo cuối kỳ này, em xin chân thành cảm ơn thầy!

TP. Hồ Chí Minh, ngày 15 tháng 12 năm 2023

Tác giả

Nguyễn Khắc Anh Tài

BÁO CÁO ĐƯỢC HOÀN THÀNH TẠI TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG

Tôi xin cam đoan đây là báo cáo của riêng tôi và được sự hướng dẫn khoa học của giảng viên Lê Anh Cường. Các nội dung báo cáo trong đề tài này là trung thực. Những số liệu trong các bảng biểu phục vụ cho việc phân tích, nhận xét, đánh giá được chính tác giả thu thập từ các nguồn khác nhau có ghi rõ trong phần tài liệu tham khảo.

Ngoài ra, trong báo cáo còn sử dụng một số nhận xét, đánh giá cũng như số liệu của các tác giả khác, cơ quan tổ chức khác đều có trích dẫn và chú thích nguồn gốc.

Nếu phát hiện có bất kỳ sự gian lận nào chúng tôi xin hoàn toàn chịu trách nhiệm về nội dung báo cáo của mình. Trường Đại học Tôn Đức Thắng không liên quan đến những vi phạm tác quyền, bản quyền do tôi gây ra trong quá trình thực hiện (nếu có).

TP. Hồ Chí Minh, ngày 15 tháng 12 năm 2023

Tác giả

Nguyễn Khắc Anh Tài

MỤC LỤC

LỜI CẢM ƠN	1
MỤC LỤC.....	3
DANH MỤC HÌNH VẼ	4
TÌM HIỂU, SO SÁNH CÁC PHƯƠNG PHÁP OPTIMIZER TRONG HUẤN LUYỆN MÔ HÌNH HỌC MÁY.....	5
1.Optimizer là gì ?.....	5
2.Các phương pháp optimizer trong huấn luyện mô hình học máy	5
2.1.Gradient Descent (GD).....	5
2.2.Stochastic Gradient Descent (SGD)	6
2.3.Momentum.....	7
2.4.Adagrad	8
2.5.RMSprop.....	9
2.6.Adam	10
3.So sánh các phương pháp Optimizer trong huấn luyện mô hình học máy.....	10
TÌM HIỂU VỀ CONTINUAL LEARNING VÀ TEST PRODUCTION	12
1.Continual Learning.....	12
1.1.Lý do cần Continual Learning.....	12
1.2.Các kỹ thuật Continual Learning	12
1.3.Các thách thức của Continual Learning	13
2.Test Production.....	13
2.1.Lợi ích của Test Production.....	14
2.2.Các cách thực hiện Test Production.....	14
2.3.Các thách thức của Test Production	14
3.Liên hệ giữa Continual Learning và Test Production	15
TÀI LIỆU THAM KHẢO	17

DANH MỤC HÌNH VẼ

<i>Hình 1: Hình so sánh đường đi của 2 phương pháp SGD và GD</i>	<i>6</i>
<i>Hình 2: Hình miêu tả thuật toán GD và GD with Momentum thông qua chuyển động của viên bi</i>	<i>7</i>
<i>Hình 3: Hình mô tả thuật toán tối ưu Adam thông qua chuyển động của viên bi</i>	<i>10</i>

TÌM HIỂU, SO SÁNH CÁC PHƯƠNG PHÁP OPTIMIZER TRONG HUẤN LUYỆN MÔ HÌNH HỌC MÁY

1. Optimizer là gì ?

- Thuật toán tối ưu (Optimizer) là cơ sở để xây dựng mô hình neural network với mục đích “học ” được các features (hay pattern) của dữ liệu đầu vào, từ đó có thể tìm 1 cặp weights và bias phù hợp để tối ưu hóa model. Trong machine learning, một optimizer là một thuật toán hoặc phương pháp được sử dụng để tối ưu hóa một hàm mất mát. Mục tiêu của quá trình tối ưu hóa là điều chỉnh các tham số của mô hình học máy để giảm thiểu giá trị của hàm mất mát, từ đó cải thiện hiệu suất dự đoán của mô hình.
- Hàm mất mát thường được định nghĩa để đo lường sự chênh lệch giữa giá trị dự đoán của mô hình và giá trị thực tế của dữ liệu huấn luyện. Quá trình tối ưu hóa thông qua optimizer giúp điều chỉnh các tham số của mô hình sao cho hàm mất mát đạt giá trị nhỏ nhất.

2. Các phương pháp optimizer trong huấn luyện mô hình học máy


2.1. Gradient Descent (GD)

- Trong các bài toán tối ưu, chúng ta thường tìm giá trị nhỏ nhất của 1 hàm số nào đó, mà hàm số đạt giá trị nhỏ nhất khi đạo hàm bằng 0. Nhưng đâu phải lúc nào đạo hàm hàm số cũng được, đối với các hàm số nhiều biến thì đạo hàm rất phức tạp, thậm chí là bất khả thi. Nên thay vào đó người ta tìm điểm gần với điểm cực tiểu nhất và xem đó là nghiệm bài toán. Gradient Descent dịch ra tiếng Việt là giảm dần độ dốc, nên hướng tiếp cận ở đây là chọn 1 nghiệm ngẫu nhiên cứ sau mỗi vòng lặp (hay epoch) thì cho nó tiến dần đến điểm cần tìm.
- Công thức : $x_{new} = x_{old} - learningrate.gradient(x)$
- Công thức trên được xây dựng để cập nhật lại nghiệm sau mỗi vòng lặp . Dấu '-' trừ ở đây ám chỉ ngược hướng đạo hàm.

- *Ưu điểm:* Thuật toán gradient descent cơ bản, dễ hiểu. Thuật toán đã giải quyết được vấn đề tối ưu model neural network bằng cách cập nhật trọng số sau mỗi vòng lặp.
- *Nhược điểm:*
 - Vì đơn giản nên thuật toán Gradient Descent còn nhiều hạn chế như phụ thuộc vào nghiệm khởi tạo ban đầu và learning rate.
 - Ví dụ 1 hàm số có 2 global minimum thì tùy thuộc vào 2 điểm khởi tạo ban đầu sẽ cho ra 2 nghiệm cuối cùng khác nhau.
 - Tốc độ học quá lớn sẽ khiến cho thuật toán không hội tụ, quanh quẩn bên đích vì bước nhảy quá lớn; hoặc tốc độ học nhỏ ảnh hưởng đến tốc độ training.

2.2. Stochastic Gradient Descent (SGD)

- Stochastic là 1 biến thể của Gradient Descent . Thay vì sau mỗi epoch chúng ta sẽ cập nhật trọng số (Weight) 1 lần thì trong mỗi epoch có N điểm dữ liệu chúng ta sẽ cập nhật trọng số N lần. Nhìn vào 1 mặt , SGD sẽ làm giảm đi tốc độ của 1 epoch. Tuy nhiên nhìn theo 1 hướng khác, SGD sẽ hội tụ rất nhanh chỉ sau vài epoch. Công thức SGD cũng tương tự như GD nhưng thực hiện trên từng điểm dữ liệu.



Hình 1: Hình so sánh đường đi của 2 phương pháp SGD và GD


- Nhìn vào hình 1, ta thấy SGD có đường đi khá là zig zắc , không mượt như GD. Dễ hiểu điều đó vì 1 điểm dữ liệu không thể đại diện cho toàn bộ dữ

liệu. Đặt câu hỏi tại sao phải dùng SGD thay cho GD mặc dù đường đi của nó khá zig zắc ? Ở đây, GD có hạn chế đối với cơ sở dữ liệu lớn (vài triệu dữ liệu) thì việc tính toán đạo hàm trên toàn bộ dữ liệu qua mỗi vòng lặp trở nên cồng kềnh. Bên cạnh đó GD không phù hợp với online learning. Vậy online learning là gì? online learning là khi dữ liệu cập nhật liên tục (ví dụ như thêm người dùng đăng kí) thì mỗi lần thêm dữ liệu ta phải tính lại đạo hàm trên toàn bộ dữ liệu nên dẫn đến thời gian tính toán lâu, thuật toán không online nữa. Vì thế SGD ra đời để giải quyết vấn đề đó, vì mỗi lần thêm dữ liệu mới vào chỉ cần cập nhật trên 1 điểm dữ liệu đó thôi, phù hợp với online learning.

- Một ví dụ minh họa : có 10.000 điểm dữ liệu thì chỉ sau 3 epoch ta đã có được nghiệm tốt, còn với GD ta phải dùng tới 90 epoch để đạt được kết quả đó.
- *Ưu điểm*: Thuật toán giải quyết được đối với cơ sở dữ liệu lớn mà GD không làm được. Thuật toán tối ưu này hiện nay vẫn hay được sử dụng.
- *Nhược điểm*: Thuật toán vẫn chưa giải quyết được 2 nhược điểm lớn của gradient descent (learning rate, điểm dữ liệu ban đầu). Vì vậy ta phải kết hợp SGD với 1 số thuật toán khác như: Momentum, AdaGrad,.. Các thuật toán này sẽ được trình bày ở phần sau.

2.3. Momentum

- Để khắc phục các hạn chế trên của thuật toán Gradient Descent người ta dùng Gradient Descent With Momentum.



Hình 2: Hình miêu tả thuật toán GD và GD with Momentum thông qua chuyển động của viên bi

- Để giải thích được Gradient with Momentum thì trước tiên ta nên nhìn dưới góc độ vật lý: Như hình b phía trên, nếu ta thả 2 viên bi tại 2 điểm khác nhau A và B thì viên bi A sẽ trượt xuống điểm C còn viên bi B sẽ trượt xuống điểm D, nhưng ta lại không mong muốn viên bi B sẽ dừng ở điểm D (local minimum) mà sẽ tiếp tục lăn tới điểm C (global minimum). Để thực hiện được điều đó ta phải cấp cho viên bi B 1 vận tốc ban đầu đủ lớn để nó có thể vượt qua điểm E tới điểm C. Dựa vào ý tưởng này người ta xây dựng nên thuật toán Momentum (tức là theo đà tiến tới).

- Nhìn dưới góc độ toán học, ta có công thức Momentum:

$$x_{new} = x_{old} - (\text{gama} \cdot v + \text{learningrate} \cdot \text{gradient})$$

- Trong đó :
 - **xnew** : tọa độ mới
 - **xold** : tọa độ cũ
 - **gama** : parameter , thường có giá trị bằng 0.9
 - **learningrate** : tốc độ học
 - **gradient** : đạo hàm của hàm f
- *Ưu điểm* : Thuật toán tối ưu giải quyết được vấn đề: Gradient Descent không tiến được tới điểm global minimum mà chỉ dừng lại ở local minimum.
- *Nhược điểm* : Tuy momentum giúp hòn bi vượt dốc tiến tới điểm đích, tuy nhiên khi tới gần đích, nó vẫn mất khá nhiều thời gian giao động qua lại trước khi dừng hẳn, điều này được giải thích vì viên bi có đà.

2.4. Adagrad

- Không giống như các thuật toán trước đó thì learning rate hầu như giống nhau trong quá trình training (learning rate là hằng số), Adagrad coi learning rate là 1 tham số. Tức là Adagrad sẽ cho learning rate biến thiên sau mỗi thời điểm t.

$$\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{G_t + \epsilon}} \odot g_t$$

- Trong đó :
 - **n** : hằng số
 - **gt** : gradient tại thời điểm t
 - **ε** : hệ số tránh lỗi (chia cho mẫu bằng 0)
 - **G** : là ma trận chéo mà mỗi phần tử trên đường chéo (i,i) là bình phương của đạo hàm vector tham số tại thời điểm t.
- *Ưu điểm* : Một lợi ích dễ thấy của Adagrad là tránh việc điều chỉnh learning rate bằng tay, chỉ cần để tốc độ học default là 0.01 thì thuật toán sẽ tự động điều chỉnh.
- *Nhược điểm* : Yếu điểm của Adagrad là tổng bình phương biến thiên sẽ lớn dần theo thời gian cho đến khi nó làm tốc độ học cực kì nhỏ, làm việc training trở nên đóng băng.

2.5. RMSprop

- RMSprop giải quyết vấn đề tỷ lệ học giảm dần của Adagrad bằng cách chia tỷ lệ học cho trung bình của bình phương gradient.

$$E[g^2]_t = 0,9E[g^2]_{t-1} + 0,1g_t^2$$

$$\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{E[g^2]_t + \epsilon}} g_t$$


- *Ưu điểm* : Ưu điểm rõ nhất của RMSprop là giải quyết được vấn đề tốc độ học giảm dần của Adagrad (vấn đề tốc độ học giảm dần theo thời gian sẽ khiến việc training chậm dần, có thể dẫn tới bị đóng băng)
- *Nhược điểm* : Thuật toán RMSprop có thể cho kết quả nghiệm chỉ là local minimum chứ không đạt được global minimum như Momentum. Vì vậy người ta sẽ kết hợp cả 2 thuật toán Momentum với RMSprop cho ra 1 thuật toán tối ưu Adam. Chúng ta sẽ trình bày nó trong phần sau.

2.6. Adam

- Adam là sự kết hợp của Momentum và RMSprop . Nếu giải thích theo hiện tượng vật lý thì Momentum giống như 1 quả cầu lao xuống dốc, còn Adam như 1 quả cầu rất nặng có ma sát, vì vậy nó dễ dàng vượt qua local minimum tới global minimum và khi tới global minimum nó không mất nhiều thời gian dao động qua lại quanh đích vì nó có ma sát nên dễ dừng lại hơn.

- Công thức :

$$\begin{aligned} g_n &\leftarrow \nabla f(\theta_{n-1}) \\ m_n &\leftarrow (\beta_1/(1-\beta_1^n)) m_{n-1} + ((1-\beta_1)/(1-\beta_1^n)) g_n \\ v_n &\leftarrow (\beta_2/(1-\beta_2^n)) v_{n-1} + ((1-\beta_2)/(1-\beta_2^n)) g_n \odot g_n \\ \theta_n &\leftarrow \theta_{n-1} - a m_n / (\sqrt{v_n} + \epsilon) , \end{aligned}$$



Hình 3: Hình mô tả thuật toán tối ưu Adam thông qua chuyển động của viên bi

3. So sánh các phương pháp Optimizer trong huấn luyện mô hình học máy

PHƯƠNG PHÁP	ƯU ĐIỂM	NHƯỢC ĐIỂM
Gradient Descent	- Đơn giản, dễ hiểu	- Phụ thuộc vào nghiệm khởi tạo ban đầu và learning rate.

		- Có thể bị mắc kẹt trong các vùng địa hình phức tạp.
Stochastic Gradient Descent	- Không phụ thuộc vào nghiệm khởi tạo ban đầu. - Nhanh chóng hội tụ. - Phù hợp với dữ liệu lớn và online learning.	- Có thể bị dao động và không ổn định.
Momentum	- Giúp vượt qua local minimum. - Tăng tốc độ hội tụ.	- Có thể bị phóng đại.
Adagrad	- Tự động điều chỉnh learning rate. - Không phụ thuộc vào nghiệm khởi tạo ban đầu.	- Tỷ lệ học có thể giảm dần theo thời gian.
RMSprop	- Giải quyết vấn đề tỷ lệ học giảm dần của Adagrad.	- Có thể cho kết quả nghiệm chỉ là local minimum.
Adam	- Kết hợp ưu điểm của Momentum và RMSprop. - Nhanh chóng hội tụ. - Ổn định.	- Khó hiểu, khó điều chỉnh.

TÌM HIỂU VỀ CONTINUAL LEARNING VÀ TEST PRODUCTION

1. Continual Learning

- Continual Learning là một lĩnh vực học máy nghiên cứu về việc đào tạo các mô hình học máy có thể học và cải thiện hiệu suất của chúng theo thời gian, ngay cả khi dữ liệu đầu vào của chúng thay đổi. Điều này trái ngược với phương pháp học máy truyền thống, trong đó các mô hình được đào tạo trên một tập dữ liệu cố định và sau đó được sử dụng để dự đoán trên dữ liệu mới.

1.1. Lý do cần Continual Learning

- Dữ liệu trong thế giới thực luôn thay đổi. Điều này có thể là do các yếu tố như:
 - Các xu hướng mới: Các xu hướng mới, chẳng hạn như xu hướng tiêu dùng mới, có thể khiến dữ liệu cũ trở nên lỗi thời.
 - Các thay đổi trong môi trường: Các thay đổi trong môi trường, chẳng hạn như thay đổi thời tiết, có thể khiến dữ liệu cũ không còn phù hợp.
 - Các lỗi trong dữ liệu: Các lỗi trong dữ liệu có thể khiến các mô hình học máy học sai.
- Continual Learning có thể giúp các mô hình học máy thích ứng với những thay đổi này và duy trì hiệu suất của chúng.

1.2. Các kỹ thuật Continual Learning

- Có nhiều kỹ thuật khác nhau có thể được sử dụng để thực hiện Continual Learning. Một số kỹ thuật phổ biến bao gồm:
 - *Incremental Learning*: Trong incremental learning, các mô hình được đào tạo trên các tập dữ liệu nhỏ, lẻ tẻ. Điều này giúp các mô hình học cách thích ứng với các thay đổi trong dữ liệu mà không bị mất đi hiệu suất đã đạt được.

Ví dụ, một mô hình học máy được đào tạo để nhận dạng khuôn mặt có thể được cập nhật với dữ liệu khuôn mặt mới khi dữ liệu này có sẵn. Điều

này sẽ giúp mô hình học cách nhận dạng các khuôn mặt mới và cải thiện hiệu suất của nó.

- *Online Learning*: Trong online learning, các mô hình được đào tạo trên dữ liệu mới khi dữ liệu đó có sẵn. Điều này cho phép các mô hình luôn cập nhật với các thay đổi trong dữ liệu.

Ví dụ, một mô hình học máy được sử dụng để dự đoán giá cổ phiếu có thể được cập nhật với dữ liệu giá cổ phiếu mới khi dữ liệu đó có sẵn.

Điều này sẽ giúp mô hình dự đoán giá cổ phiếu chính xác hơn.

- *Transfer Learning*: Trong transfer learning, các mô hình được đào tạo trên một tập dữ liệu cho một nhiệm vụ cụ thể được sử dụng làm điểm khởi đầu cho việc đào tạo trên một tập dữ liệu khác cho một nhiệm vụ khác. Điều này giúp các mô hình học cách học nhanh hơn và hiệu quả hơn.

Ví dụ, một mô hình học máy được đào tạo để nhận dạng các vật thể có thể được sử dụng làm điểm khởi đầu cho việc đào tạo một mô hình học máy mới được sử dụng để nhận dạng các khuôn mặt. Điều này sẽ giúp mô hình mới học cách nhận dạng khuôn mặt nhanh hơn và hiệu quả hơn.

1.3. Các thách thức của Continual Learning

- Continual Learning là một lĩnh vực học máy mới nổi và vẫn còn nhiều thách thức cần giải quyết. Một số thách thức chính bao gồm:
 - Vấn đề về sự ổn định: Các mô hình học máy có thể bị mất ổn định khi được cập nhật với dữ liệu mới.
 - Vấn đề về hiệu suất: Quá trình cập nhật mô hình có thể làm giảm hiệu suất của mô hình.
 - Vấn đề về chi phí: Quá trình cập nhật mô hình có thể tốn kém.

2. Test Production

- Test Production là một quá trình trong đó một mô hình học máy được triển khai vào sản xuất trong khi vẫn được theo dõi và đánh giá. Điều này cho

phép các nhà phát triển học máy thu thập dữ liệu về hiệu suất của mô hình trong điều kiện thực tế và thực hiện các điều chỉnh cần thiết.

2.1. Lợi ích của Test Production

- Test Production có thể mang lại nhiều lợi ích cho các nhà phát triển học máy, bao gồm:
 - Đảm bảo chất lượng của mô hình: Test Production cho phép các nhà phát triển học máy xác định xem mô hình của họ có hoạt động tốt như mong đợi hay không trong điều kiện thực tế. Điều này có thể giúp ngăn ngừa việc triển khai các mô hình học máy kém chất lượng.
 - Tăng hiệu suất của mô hình: Test Production cho phép các nhà phát triển học máy xác định xem có bất kỳ cách nào để cải thiện hiệu suất của mô hình hay không. Điều này có thể giúp các mô hình học máy hoạt động tốt hơn trong điều kiện thực tế.
 - Loại bỏ các lỗi của mô hình: Test Production cho phép các nhà phát triển học máy xác định và khắc phục các lỗi của mô hình. Điều này có thể giúp cải thiện độ tin cậy của các mô hình học máy.

2.2. Các cách thực hiện Test Production

- Có nhiều cách khác nhau để thực hiện Test Production. Một cách phổ biến là sử dụng một tập dữ liệu thử nghiệm để đánh giá hiệu suất của mô hình. Tập dữ liệu thử nghiệm là một tập dữ liệu độc lập với tập dữ liệu được sử dụng để đào tạo mô hình. Điều này giúp đảm bảo rằng hiệu suất của mô hình trong điều kiện thực tế là chính xác.
- Một cách khác để thực hiện Test Production là sử dụng một tập dữ liệu sản xuất để đánh giá hiệu suất của mô hình. Tập dữ liệu sản xuất là tập dữ liệu mà mô hình sẽ được sử dụng để dự đoán trong sản xuất. Điều này cung cấp cho các nhà phát triển học máy một bức tranh thực tế về cách mô hình sẽ hoạt động trong điều kiện thực tế.

2.3. Các thách thức của Test Production

- Test Production là một quá trình phức tạp và đòi hỏi nhiều công sức. Một số thách thức chính bao gồm:
 - Vấn đề về dữ liệu: Tập dữ liệu thử nghiệm hoặc sản xuất phải đủ lớn và đại diện để đánh giá chính xác hiệu suất của mô hình.
 - Vấn đề về thời gian: Quá trình đánh giá hiệu suất của mô hình có thể tốn thời gian và tốn kém.

3. Liên hệ giữa Continual Learning và Test Production

- Continual Learning và Test Production là hai kỹ thuật quan trọng có thể được sử dụng để cải thiện hiệu quả của các giải pháp học máy. Continual Learning giúp các mô hình học máy học cách thích ứng với các thay đổi trong dữ liệu, trong khi Test Production giúp đảm bảo chất lượng của mô hình trong điều kiện thực tế.
- Cả hai kỹ thuật này đều có thể được sử dụng kết hợp với nhau để tạo ra các giải pháp học máy hiệu quả hơn. Continual Learning có thể được sử dụng để cập nhật các mô hình học máy với dữ liệu mới, trong khi Test Production có thể được sử dụng để đánh giá hiệu suất của các mô hình đã được cập nhật.
- Ví dụ, một mô hình học máy có thể được đào tạo trên một tập dữ liệu lớn của dữ liệu lịch sử. Sau đó, mô hình có thể được triển khai vào sản xuất và theo dõi trong Test Production. Nếu hiệu suất của mô hình giảm, các nhà phát triển học máy có thể sử dụng Continual Learning để cập nhật mô hình với dữ liệu mới. Điều này sẽ giúp mô hình học cách thích ứng với các thay đổi trong dữ liệu và duy trì hiệu suất của nó.
- Cụ thể, Continual Learning có thể được sử dụng để:
 - Giúp các mô hình học máy thích ứng với các thay đổi trong dữ liệu đầu vào, chẳng hạn như các xu hướng mới, các thay đổi trong môi trường hoặc các lỗi trong dữ liệu.
 - Cải thiện hiệu suất của các mô hình học máy trong điều kiện thực tế.
 - Giảm nhu cầu đào tạo lại các mô hình học máy.
- Trong khi đó, Test Production có thể được sử dụng để:

- Đảm bảo chất lượng của các mô hình học máy trong điều kiện thực tế.
 - Tìm ra các lỗi trong các mô hình học máy.
 - Cải thiện hiệu suất của các mô hình học máy.
- Việc kết hợp Continual Learning và Test Production có thể giúp các nhà phát triển học máy xây dựng các giải pháp học máy hiệu quả hơn và bền vững hơn.
- Tóm lại, Continual Learning và Test Production đều liên quan đến việc duy trì và cải thiện hệ thống. Test Production chủ yếu tập trung vào chất lượng và độ ổn định của sản phẩm, trong khi Continual Learning chú trọng vào khả năng học liên tục của mô hình trong môi trường thay đổi. Sự tương tác giữa hai lĩnh vực này đặt ra những thách thức và cơ hội trong việc phát triển và triển khai các hệ thống học máy phức tạp.

TÀI LIỆU THAM KHẢO

- [1]. Trần Trung Trực, [2020], [Optimizer- Hiểu sâu về các thuật toán tối ưu \(GD,SGD,Adam,...\)](#)
- [2]. amananandrai, [2020], [10 famous Machine Learning Optimizers](#)
- [3]. ML Glossary, [2017], [Optimizers](#)
- [4]. Dianne Castillo, [2021], [Machine Learning Optimization – Why is it so Important?](#)
- [5]. Datacamp, [2023], [What is Continuous Learning? Revolutionizing Machine Learning & Adaptability](#)
- [6] wikicontinualai, [2021], [Introduction to Continual Learning](#)
- [7] Eugene Yan, [2023], [Machine Learning in Production - Testing](#)
- [8] Gokul Mohandas, [2020], [Testing Machine Learning Systems: Code, Data and Models](#)