

TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN



NHẬP MÔN HỌC MÁY
TIỂU LUẬN CUỐI KÌ

Người hướng dẫn: **TS. LÊ ANH CƯỜNG**

Người thực hiện: **TRẦN NAM ĐĂNG KHOA - 52100239**

Khoá: 25

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2023

TỔNG LIÊN ĐOÀN LAO ĐỘNG VIỆT NAM
TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG
KHOA CÔNG NGHỆ THÔNG TIN



NHẬP MÔN HỌC MÁY
TIỂU LUẬN CUỐI KÌ

Người hướng dẫn: **TS. LÊ ANH CƯỜNG**

Người thực hiện: **TRẦN NAM ĐĂNG KHOA- 52100239**

Khoá: 25

THÀNH PHỐ HỒ CHÍ MINH, NĂM 2023

LỜI CẢM ƠN

Để hoàn thành bài báo cáo này, chúng em xin cảm ơn đến TS Lê Anh Cường đã hướng dẫn cho em đi từ những cái cơ bản nhất của môn Nhập môn học máy để chúng em có thể có đủ kiến thức hoàn thành bài tiểu luận cuối kỳ này, chúng em xin chân thành cảm ơn!

TP. Hồ Chí Minh, ngày 22 tháng 12 năm 2023

Tác giả

(Ký tên và ghi rõ họ tên)

BÁO CÁO ĐƯỢC HOÀN THÀNH TẠI TRƯỜNG ĐẠI HỌC TÔN ĐỨC THẮNG

Tôi xin cam đoan đây là báo cáo của riêng chúng tôi và được sự hướng dẫn khoa học của thầy Lê Anh Cường. Các nội dung báo cáo, kết quả trong đề tài này là trung thực. Những số liệu trong các bảng biểu phục vụ cho việc phân tích, nhận xét, đánh giá được chính tác giả thu thập từ các nguồn khác nhau có ghi rõ trong phần tài liệu tham khảo.

Ngoài ra, trong báo cáo còn sử dụng một số nhận xét, đánh giá cũng như số liệu của các tác giả khác, cơ quan tổ chức khác đều có trích dẫn và chú thích nguồn gốc.

Nếu phát hiện có bất kỳ sự gian lận nào chúng tôi xin hoàn toàn chịu trách nhiệm về nội dung báo cáo của mình. Trường Đại học Tôn Đức Thắng không liên quan đến những vi phạm tác quyền, bản quyền do tôi gây ra trong quá trình thực hiện (nếu có).

TP. Hồ Chí Minh, ngày 22 tháng 12 năm 2023

Tác giả

(Ký tên và ghi rõ họ tên)

MỤC LỤC

LỜI CẢM ƠN.....	i
DANH MỤC HÌNH ẢNH.....	i
DANH MỤC CÁC CHỮ VIẾT TẮT.....	iii
PHẦN 1: TÌM HIỂU, SO SÁNH CÁC PHƯƠNG PHÁP OPTIMIZER TRONG HUẤN LUYỆN MÔ HÌNH HỌC MÁY	1
1.1 Giới thiệu	1
1.2 Tổng quan về Optimizer	2
1.2.1 Định nghĩa và vai trò của Optimizer	2
1.2.2 Mục tiêu của việc tìm hiểu và so sánh các phương pháp Optimizer	2
1.3 Các phương pháp Optimizer phổ biến.....	3
1.3.1 Gradient Descent (GD)	3
1.3.1.1 Giải thích cơ bản về Gradient Descent và cách hoạt động.....	3
1.3.1.2 Hai biến thể quan trọng của Gradient Descent.....	3
1.3.1.3 Ưu điểm và nhược điểm của GD	4
1.3.2 Momentum	4
1.3.2.1 Định nghĩa	4
1.3.2.2 Cách Momentum giúp giảm độ dao động và tăng tốc quá trình hội tụ	7
1.3.2.3 Ưu điểm và nhược điểm của Momentum	7
1.3.3 Adam.....	8
1.3.3.1 Định nghĩa và cơ chế hoạt động của phương pháp Adam	8
1.3.3.2 Các thành phần chính của Adam.....	8
1.3.3.3 Ưu điểm và nhược điểm của Adam.....	9
1.4 So sánh các phương pháp Optimizer	9
1.5 Kết luận.....	11

PHẦN 2: TÌM HIỂU VỀ CONTINUAL LEARNING VÀ TEST PRODUCT

2.1 Giới thiệu.....	12
2.2 Continual Learning.....	12
2.2.1 Định nghĩa	12
2.2.2 Các bài toán về Continual Learning	13
2.2.3 Các phương pháp và kỹ thuật phổ biến được sử dụng trong lĩnh vực Continual Learning.....	13
2.2.4 Ưu điểm và hạn chế của từng phương pháp.....	14
2.3 Test Production	15
2.3.1 Định nghĩa	15
2.3.2 Vấn đề và thách thức khi thực hiện kiểm thử trong xây dựng giải pháp học máy.....	15
2.3.3 Các kỹ thuật và phương pháp kiểm thử phổ biến	16
2.3.4 Ưu điểm và hạn chế của từng phương pháp kiểm thử.....	16
2.3.5 Tiêu chí và phương pháp đánh giá hiệu suất của một giải pháp học máy	19
2.3.6 Kết hợp Continual Learning và Test Production	19
2.4 Kết luận	21
TÀI LIỆU THAM KHẢO	22

DANH MỤC HÌNH ẢNH

Hình 1.1: Ví dụ mô tả GD without Momentum.....	6
--	---

DANH MỤC BẢNG BIỂU

Bảng 1.1: Bảng so sánh về hiệu suất và ưu điểm các phương pháp Optimizer	9
--	---

DANH MỤC CÁC CHỮ VIẾT TẮT

BGD	Batch Gradient Descent
GD	Gradient Descent
SGD	Stochastic Gradient Descent

PHẦN 1: TÌM HIỂU, SO SÁNH CÁC PHƯƠNG PHÁP OPTIMIZER TRONG HUẤN LUYỆN MÔ HÌNH HỌC MÁY

1.1 Giới thiệu

Trong lĩnh vực học máy, quá trình huấn luyện mô hình là một phần quan trọng và tốn nhiều thời gian nhất. Để đạt được hiệu suất tốt và hội tụ nhanh chóng, việc lựa chọn phương pháp Optimizer phù hợp là vô cùng quan trọng. Phương pháp Optimizer đóng vai trò quyết định trong việc tối ưu hóa hiệu suất của mô hình học máy. Hiểu rõ và nghiên cứu các phương pháp Optimizer giúp tăng cường khả năng dự báo và đạt được hiệu suất tối ưu trong huấn luyện mô hình học máy.

Trong bối cảnh này, chủ đề nghiên cứu về các phương pháp Optimizer trong huấn luyện mô hình học máy đã được lựa chọn để tìm hiểu và khám phá những lợi ích và tầm quan trọng của việc nghiên cứu này.

Mục tiêu chính của nghiên cứu này là tìm hiểu và đánh giá các phương pháp Optimizer khác nhau và xác định những ưu điểm, hạn chế và tác động của chúng đối với quá trình huấn luyện mô hình học máy.

Lý do lựa chọn chủ đề này là do tầm quan trọng của phương pháp Optimizer trong huấn luyện mô hình học máy. Một phương pháp Optimizer tốt và phù hợp có thể giúp tăng cường hiệu suất và tốc độ hội tụ của mô hình, đồng thời giải quyết các vấn đề như gradient vanishing và gradient exploding. Điều này đóng góp vào tạo ra những mô hình học máy có khả năng dự báo chính xác và ổn định trên dữ liệu mới.

Nghiên cứu các phương pháp Optimizer trong huấn luyện mô hình học máy cũng đóng góp vào sự phát triển và tiến bộ của lĩnh vực học máy. Hiểu rõ cơ chế hoạt động và lựa chọn phương pháp Optimizer phù hợp là nền tảng để phát triển những phương pháp tối ưu hóa mới và nâng cao hiệu suất của mô hình học máy.

Với những lợi ích và tầm quan trọng của việc nghiên cứu các phương pháp Optimizer trong huấn luyện mô hình học máy, chúng ta có thể hi vọng rằng nghiên cứu này sẽ đóng góp vào sự tiến bộ và ứng dụng trong các lĩnh vực thực tế và mang lại những kết quả tích cực cho cộng đồng học máy và trí tuệ nhân tạo.

1.2 Tổng quan về Optimizer

1.2.1 Định nghĩa và vai trò của Optimizer

Trong quá trình huấn luyện mô hình học máy, Optimizer là một thành phần quan trọng để tối ưu hóa các tham số của mô hình dựa trên độ lỗi và Gradient của hàm mất mát. Hàm mất mát đo lường sự khác biệt giữa giá trị dự đoán và giá trị thực tế, trong khi Gradient là đạo hàm của hàm mất mát theo các tham số.

Optimizer giúp điều chỉnh các tham số của mô hình theo hướng tối ưu hóa để đạt được giá trị mất mát nhỏ nhất. Điều này đồng nghĩa với việc tìm kiếm bộ tham số tối ưu để mô hình có khả năng dự đoán chính xác và tổng quát hóa tốt trên dữ liệu mới.

1.2.2 Mục tiêu của việc tìm hiểu và so sánh các phương pháp Optimizer

Tìm hiểu ưu điểm và hạn chế của từng phương pháp: Mỗi phương pháp Optimizer có những đặc điểm riêng, điều này ảnh hưởng đến hiệu suất và tốc độ hội tụ của quá trình huấn luyện.

Tăng cường hiệu suất và tốc độ hội tụ: Mục tiêu cuối cùng của việc tìm hiểu các phương pháp Optimizer là cải thiện hiệu suất và tốc độ hội tụ của quá trình huấn luyện mô hình. Bằng cách lựa chọn phương pháp Optimizer phù hợp và tinh chỉnh các tham số liên quan, chúng ta có thể giảm thiểu độ lỗi và tăng tốc quá trình hội tụ, từ đó cải thiện khả năng dự đoán của mô hình.

Áp dụng vào các lĩnh vực thực tế: Hiểu rõ về các phương pháp Optimizer và ưu điểm của chúng giúp chúng ta áp dụng chúng vào các lĩnh vực thực tế. Các ứng dụng của mô hình học máy ngày càng phổ biến, và việc áp dụng các phương pháp Optimizer tối ưu hóa hiệu suất của mô hình là rất quan trọng.

1.3 Các phương pháp Optimizer phổ biến

1.3.1 Gradient Descent (GD)

1.3.1.1 Giải thích cơ bản về Gradient Descent và cách hoạt động

Gradient Descent (GD) là một phương pháp tối ưu hóa cơ bản trong Machine Learning. Nó dựa trên ý tưởng cập nhật các tham số của mô hình dựa trên đạo hàm của hàm mất mát. Mục tiêu của GD là tìm ra bộ tham số mô hình để giảm thiểu độ lỗi.

Cách hoạt động của GD:

- Bước 1: Khởi tạo ngẫu nhiên các giá trị ban đầu cho các tham số của mô hình.
- Bước 2: Tính gradient của hàm mất mát theo từng tham số.
- Bước 3: Cập nhật các tham số bằng cách di chuyển theo hướng ngược với gradient, nhân với một tỉ lệ học (learning rate) để điều chỉnh tốc độ cập nhật.
- Bước 4: Lặp lại bước 2 và 3 cho đến khi đạt được điều kiện dừng, ví dụ như đạt đủ số lần lặp hoặc đạt được độ lỗi mong muốn.

Công thức: $\mathbf{x}(\text{new}) = \mathbf{x}(\text{old}) - \text{learningrate} \cdot \text{gradient}(\mathbf{x})$

1.3.1.2 Hai biến thể quan trọng của Gradient Descent

Batch Gradient Descent (BGD): BGD tính gradient bằng cách lấy trung bình gradient của toàn bộ tập dữ liệu huấn luyện. Sau đó, nó cập nhật các tham số mô hình dựa trên gradient này. BGD có thể đạt được tốc độ hội tụ ổn định, nhưng nó yêu cầu tính toán đầy đủ trên toàn bộ tập dữ liệu, điều này có thể chậm khi dữ liệu lớn.

Stochastic Gradient Descent (SGD): SGD tính gradient và cập nhật tham số cho từng mẫu dữ liệu huấn luyện một cách ngẫu nhiên. Do chỉ tính toán trên một mẫu,

SGD có tốc độ hội tụ nhanh hơn và có khả năng làm việc với tập dữ liệu lớn. Tuy nhiên, SGD có thể gây ra độ dao động cao và không ổn định hơn BGD.

1.3.1.3 Ưu điểm và nhược điểm của GD

Ưu điểm:

- Thuật toán gradient descent cơ bản, dễ hiểu.
- Giải quyết được vấn đề tối ưu model neural network bằng cách cập nhật trọng số sau mỗi vòng lặp.
- Hoạt động tốt trên tập dữ liệu nhỏ hoặc có nhiều dữ liệu giống nhau

Nhược điểm:

- Cần tính toán đầy đủ trên toàn bộ tập dữ liệu trong trường hợp BGD, làm chậm quá trình huấn luyện trên dữ liệu lớn.
- Có thể gặp vấn đề với độ dao động và không ổn định trong trường hợp SGD.

1.3.2 Momentum

1.3.2.1 Định nghĩa

Để khắc phục các hạn chế trên của thuật toán Gradient Descent người ta dùng Gradient Descent with Momentum.

Momentum là phương pháp tối ưu hóa được thiết kế để giảm độ dao động và tăng tốc quá trình hội tụ. Nó sử dụng một trọng số động để tích lũy đà của các bước cập nhật trước đó.

Nhìn dưới góc độ toán học, ta có công thức Momentum:

$$\mathbf{x}(\text{new}) = \mathbf{x}(\text{old}) - (\text{gama.v} + \text{learningrate.gradient})$$

Trong đó:



$x(\text{new})$: Tọa độ mới

$x(\text{old})$: Tọa độ cũ

γ : parameter, thường = 0.9

learning: tốc độ học

gradient: đạo hàm của hàm f



Hình 1.1: Ví dụ mô tả GD without Momentum

Qua 2 ví dụ minh họa trên của hàm $f(x) = x^2 + 10\sin(x)$, ta thấy GD without momentum sẽ hội tụ sau 5 vòng lặp nhưng không phải là global minimum. Nhưng GD with momentum dù mất nhiều vòng lặp nhưng nghiệm tiến tới global minimum, qua hình ta thấy nó sẽ vượt tốc tiến tới điểm global minimum và dao động qua lại quanh điểm đó trước khi dừng lại.

1.3.2.2 Cách Momentum giúp giảm độ dao động và tăng tốc quá trình hội tụ

- Trong mỗi bước cập nhật, Momentum sẽ tính toán một vector động Momentum dựa trên gradient hiện tại và vector động Momentum của các bước cập nhật trước đó.

- Vector động Momentum sẽ được sử dụng để điều chỉnh tốc độ cập nhật của các tham số mô hình. Nó giúp giảm độ dao động bằng cách ổn định hướng di chuyển và tăng tốc quá trình hội tụ bằng cách tích lũy đà.

1.3.2.3 Ưu điểm và nhược điểm của Momentum

Ưu điểm:

- Thuật toán tối ưu giải quyết được vấn đề: Gradient Descent không tiến được tới điểm global minimum mà chỉ dừng lại ở local minimum.

- Giúp giảm độ dao động và làm cho quá trình hội tụ ổn định hơn.

- Cải thiện tốc độ hội tụ của quá trình huấn luyện.

Nhược điểm:

- Tuy Momentum giúp hòn bi vượt dốc tiến tới điểm đích, tuy nhiên khi tới gần đích, nó vẫn mất khá nhiều thời gian giao động qua lại trước khi dừng hẳn, điều này được giải thích vì viên bi có đà.

- Cần điều chỉnh các siêu tham số, như hệ số momentum, để đạt được hiệu quả tốt. Việc lựa chọn sai siêu tham số có thể ảnh hưởng đến hiệu suất của phương pháp.

- Có thể gặp vấn đề khi mô hình có nhiều cực tiểu cục bộ.

1.3.3 Adam

1.3.3.1 Định nghĩa và cơ chế hoạt động của phương pháp Adam

Adam (Adaptive Moment Estimation) là một phương pháp tối ưu hóa kết hợp các ưu điểm của Momentum và RMSprop.

Nó sử dụng kỹ thuật tỷ lệ học thích ứng và tích lũy động Moment để cập nhật tham số mô hình.

Công thức:

$$\begin{aligned} \mathbf{g}_n &\leftarrow \nabla f(\boldsymbol{\theta}_{n-1}) \\ \mathbf{m}_n &\leftarrow (\beta_1/(1 - \beta_1^n)) \mathbf{m}_{n-1} + ((1 - \beta_1)/(1 - \beta_1^n)) \mathbf{g}_n \\ \mathbf{v}_n &\leftarrow (\beta_2/(1 - \beta_2^n)) \mathbf{v}_{n-1} + ((1 - \beta_2)/(1 - \beta_2^n)) \mathbf{g}_n \odot \mathbf{g}_n \\ \boldsymbol{\theta}_n &\leftarrow \boldsymbol{\theta}_{n-1} - a \mathbf{m}_n / (\sqrt{\mathbf{v}_n} + \epsilon), \end{aligned}$$

1.3.3.2 Các thành phần chính của Adam

- Momen động (Momentum): Tích lũy đà của các bước cập nhật trước đó, tương tự như trong Momentum.

- Tỷ lệ học (Learning rate): Điều chỉnh tốc độ cập nhật tham số.

- Tích lũy động Moment (Adam's moving average): Tích lũy thông tin về gradient của các bước cập nhật trước đó để điều chỉnh tốc độ cập nhật.

1.3.3.3 Ưu điểm và nhược điểm của Adam

Ưu điểm

- Hiệu quả trên nhiều loại bài toán và tập dữ liệu.
- Tính toán hiệu quả và tốc độ hội tụ tốt.

Nhược điểm:

- Yêu cầu điều chỉnh các siêu tham số để đạt hiệu suất tốt.
- Có thể có hiện tượng độ dao động trong quá trình huấn luyện.

1.4 So sánh các phương pháp Optimizer

Bảng 1.1: Bảng so sánh về hiệu suất và ưu điểm các phương pháp Optimizer

Phương pháp	Tốc độ hội tụ	Khả năng tránh cực tiểu cục bộ	Khả năng hoạt động trên tập dữ liệu lớn	Xử lý vấn đề đặc biệt trong quá trình huấn luyện
GD	Trung bình	Dễ rơi vào cực tiểu cục bộ	Chậm trên tập dữ liệu lớn	Dễ bị ảnh hưởng bởi đặc điểm dữ liệu
Momentum	Nhanh	Giảm độ dao động	Hoạt động tốt trên tập dữ liệu lớn	Yêu cầu điều chỉnh siêu tham số momentum
Adam	Nhanh	Giảm độ dao động, ổn định	Hoạt động tốt trên tập dữ liệu lớn	Yêu cầu điều chỉnh các siêu tham số

Phân tích và đánh giá sự ảnh hưởng của các yếu tố như tốc độ hội tụ, khả năng tránh rơi vào cực tiểu cục bộ, khả năng hoạt động trên tập dữ liệu lớn và khả năng xử lý các vấn đề đặc biệt trong quá trình huấn luyện:

- Tốc độ hội tụ:

- GD: Tốc độ hội tụ của GD trung bình, không nhanh nhất nhưng cũng không chậm nhất.
- Momentum và Adam: Cả hai phương pháp này thường có tốc độ hội tụ nhanh hơn GD nhờ tính chất tích lũy đà và thông tin gradient của các bước cập nhật trước đó.

- Khả năng tránh rơi vào cực tiểu cục bộ:

- GD: GD dễ rơi vào cực tiểu cục bộ do chỉ di chuyển theo gradient hiện tại mà không quan tâm đến thông tin quá khứ.
- Momentum và Adam: Momentum và Adam có khả năng giảm độ dao động và tránh rơi vào cực tiểu cục bộ hơn do tích lũy đà và thông tin gradient của các bước cập nhật trước đó.

- Khả năng hoạt động trên tập dữ liệu lớn:

- GD: GD có thể chậm trên tập dữ liệu lớn vì yêu cầu tính toán đầy đủ trên toàn bộ tập dữ liệu.
- Momentum và Adam: Cả hai phương pháp này hoạt động tốt trên tập dữ liệu lớn do tính chất của tích lũy đà và thông tin gradient chỉ được tính trên một mẫu hoặc một mini-batch.

- Xử lý vấn đề đặc biệt trong quá trình huấn luyện:

- GD: GD dễ bị ảnh hưởng bởi đặc điểm dữ liệu, như độ lớn của các đặc trưng. Điều này có thể làm cho quá trình huấn luyện không ổn định và khó hội tụ.

- Momentum và Adam: Cả hai phương pháp này có khả năng xử lý các vấn đề đặc biệt trong quá trình huấn luyện như độ dao động, gradient bị thưa thớt, tỷ lệ học tập khác nhau cho các tham số.

➔ Tuy nhiên, việc điều chỉnh siêu tham số là một thách thức trong cả Momentum và Adam. Nếu không được điều chỉnh đúng, chúng có thể gây ra sự dao động không mong muốn hoặc làm chậm quá trình hội tụ.

➔ Tóm lại, Adam là một phương pháp tốt để bắt đầu với do nó kết hợp lợi thế của Momentum và RMSProp (một phương pháp khác để điều chỉnh tỷ lệ học tập). Tuy nhiên, việc điều chỉnh siêu tham số là một yếu tố quan trọng và cần được thực hiện cẩn thận để đạt được hiệu suất tốt nhất.

1.5 Kết luận

Chúng ta đã xem xét và so sánh ba phương pháp Optimizer phổ biến trong huấn luyện mô hình học máy: Gradient Descent (GD), Momentum và Adam. Việc lựa chọn phương pháp Optimizer phù hợp rất quan trọng để đạt hiệu suất tốt trong huấn luyện mô hình học máy. Các hướng nghiên cứu tiềm năng bao gồm tối ưu hóa và tự động điều chỉnh siêu tham số của Optimizer và phát triển các phương pháp Optimizer mới.

PHẦN 2: TÌM HIỂU VỀ CONTINUAL LEARNING VÀ TEST PRODUCT

2.1 Giới thiệu

Trong thời đại số hóa hiện nay, học máy (machine learning) đã trở thành một công cụ mạnh mẽ để giải quyết các bài toán phức tạp và tạo ra những đột phá trong nhiều lĩnh vực, từ nhận dạng hình ảnh cho đến dự báo thị trường tài chính. Học máy là một lĩnh vực của trí tuệ nhân tạo (AI) nghiên cứu cách làm cho máy tính học từ dữ liệu và cải thiện hiệu suất theo thời gian.

Tuy nhiên, trong thực tế, môi trường và dữ liệu thường không ổn định và thay đổi liên tục. Các bài toán học máy đòi hỏi khả năng học liên tục (continual learning) và kiểm thử (test production) hiệu quả để đáp ứng nhu cầu thay đổi của thị trường và cập nhật dữ liệu mới.

Học liên tục (continual learning) là khả năng của một hệ thống học máy để tiếp tục học và cải thiện từ các dữ liệu mới mà nó chưa từng trải nghiệm trước đó. Điều này cho phép hệ thống học máy thích ứng với sự thay đổi trong môi trường và duy trì hiệu suất cao theo thời gian. Đồng thời, kiểm thử (test production) đóng vai trò quan trọng trong việc đánh giá hiệu suất của một giải pháp học máy và đảm bảo rằng nó hoạt động đúng đắn trên dữ liệu mới.

Vì vậy, trong bài luận này, chúng ta sẽ tìm hiểu về Continual Learning và Test Production khi xây dựng một giải pháp học máy để giải quyết một bài toán cụ thể. Chúng ta sẽ khám phá các thách thức và vấn đề liên quan đến việc triển khai học liên tục và kiểm thử trong lĩnh vực học máy, cùng với các phương pháp và kỹ thuật phổ biến được sử dụng để đối phó với những thách thức này.

2.2 Continual Learning

2.2.1 Định nghĩa

Continual Learning (học liên tục) là khả năng của một hệ thống học máy để tiếp tục học và cải thiện hiệu suất từ các dữ liệu mới mà nó chưa từng trải nghiệm

trước đó. Tuy nhiên, triển khai học liên tục đối mặt với một số thách thức, bao gồm hiện tượng quên (catastrophic forgetting) và đòi hỏi tài nguyên tính toán và bộ nhớ.

2.2.2 Các bài toán về Continual Learning

Continual Learning có thể được áp dụng trong nhiều bài toán học máy khác nhau như: nhận dạng đối tượng, dịch thuật tự động, xử lý ngôn ngữ tự nhiên, v.v.

Ví dụ:

Trong bài toán nhận dạng đối tượng, continual learning cho phép hệ thống học máy nhận biết và phân loại các đối tượng mới mà nó chưa từng gặp trước đó mà không làm ảnh hưởng đến khả năng nhận dạng các đối tượng cũ.

Tương tự, trong dịch thuật tự động, học liên tục giúp hệ thống học máy cải thiện khả năng dịch mới mà không làm giảm khả năng dịch các văn bản cũ.

Xử lý ngôn ngữ tự nhiên cũng là một lĩnh vực có thể áp dụng học liên tục, giúp hệ thống học máy hiểu và tạo ra ngôn ngữ mới trong quá trình giao tiếp.

2.2.3 Các phương pháp và kỹ thuật phổ biến được sử dụng trong lĩnh vực Continual Learning

Có nhiều phương pháp và kỹ thuật phổ biến được sử dụng trong lĩnh vực Continual Learning:

- Elastic Weight Consolidation (EWC) là một phương pháp phổ biến, nó giữ lại những kiến thức quan trọng từ các tác vụ trước đó bằng cách áp dụng trọng số cho các tham số quan trọng.
- Online Learning là một phương pháp khác, trong đó hệ thống học máy tiếp tục cập nhật và điều chỉnh mô hình dự đoán một cách trực tiếp trên dữ liệu mới.
- Rehearsal Methods là phương pháp sử dụng lại các mẫu dữ liệu cũ để giúp hệ thống học máy nhớ lại và duy trì kiến thức trước đó.

2.2.4 Ưu điểm và hạn chế của từng phương pháp

- Elastic Weight Consolidation (EWC):

- Ưu điểm: EWC giữ lại kiến thức quan trọng từ các tác vụ trước đó bằng cách áp dụng trọng số cho các tham số quan trọng. Điều này giúp hạn chế hiện tượng quên và duy trì hiệu suất trên các tác vụ đã học. EWC cũng tương đối dễ triển khai và không đòi hỏi nhiều tài nguyên tính toán.
- Hạn chế: EWC có thể gặp khó khăn khi áp dụng cho các tác vụ phức tạp. Nếu có quá nhiều tác vụ hoặc các tác vụ có quan hệ phức tạp, việc xác định trọng số quan trọng có thể trở nên khó khăn. Đồng thời, EWC cũng yêu cầu lưu trữ thông tin về trọng số quan trọng, đòi hỏi bộ nhớ phụ và tăng thêm chi phí tính toán.

- Online Learning:

- Ưu điểm: Online Learning cho phép hệ thống học máy cập nhật mô hình dự đoán một cách trực tiếp trên dữ liệu mới. Điều này giúp nhanh chóng thích nghi với dữ liệu mới và giữ được hiệu suất tốt trên các tác vụ mới. Phương pháp này không đòi hỏi lưu trữ thông tin quá khứ và thích hợp cho các tác vụ độc lập.
- Hạn chế: Một trong những hạn chế của Online Learning là khả năng quên nhanh chóng kiến thức cũ. Khi mô hình cập nhật liên tục trên dữ liệu mới, nó có thể ghi đè lên kiến thức cũ và làm mất thông tin quan trọng từ các tác vụ trước. Điều này đặc biệt đáng chú ý khi dữ liệu mới và cũ có sự chồng chéo hoặc tương đồng.

- Rehearsal Methods:

- Ưu điểm: Rehearsal Methods sử dụng lại các mẫu dữ liệu cũ để giúp hệ thống học máy nhớ và duy trì kiến thức trước đó. Điều này giúp giảm hiện tượng quên và hỗ trợ học liên tục trên các tác vụ khác nhau.

Rehearsal Methods không yêu cầu thông tin về trọng số quan trọng hoặc lưu trữ toàn bộ dữ liệu cũ.

- Hạn chế: Một trong những hạn chế của Rehearsal Methods là yêu cầu bộ nhớ đủ lớn để lưu trữ các mẫu dữ liệu cũ. Nếu số lượng mẫu dữ liệu cũ lớn hoặc không thể lưu trữ trong bộ nhớ hiện có, việc sử dụng lại dữ liệu cũ trở nên khó khăn. Ngoài ra, Rehearsal Methods có thể gây ra hiện tượng can thiệp (interference), khi dữ liệu cũ và mới can thiệp lẫn nhau và ảnh hưởng đến hiệu suất hệ thống.

2.3 Test Production

2.3.1 Định nghĩa

Test Production là quá trình thực hiện kiểm thử một giải pháp học máy trong môi trường thực tế hoặc sản xuất. Nó đảm bảo rằng giải pháp học máy hoạt động đúng và đáng tin cậy trên dữ liệu mới, không được sử dụng trong quá trình huấn luyện. Test Production giúp đánh giá hiệu suất thực tế của giải pháp và xác định khả năng tổng quát hóa.

2.3.2 Vấn đề và thách thức khi thực hiện kiểm thử trong xây dựng giải pháp học máy

- Khả năng tổng quát hóa: Một giải pháp học máy có thể hoạt động tốt trên dữ liệu huấn luyện nhưng không hiệu quả trên dữ liệu mới. Điều này thường gây ra hiện tượng overfitting. Kiểm thử phải kiểm tra khả năng tổng quát hóa của mô hình.

- Dữ liệu không cân bằng: Khi dữ liệu thuộc về các lớp khác nhau không cân bằng về số lượng, đánh giá hiệu suất có thể bị mất cân đối. Điều này đặc biệt quan trọng trong các bài toán phân loại.

- Overfitting và underfitting: Mô hình có thể bị overfitting (quá khớp) hoặc underfitting (quá đơn giản) trên dữ liệu kiểm thử. Điều này yêu cầu kiểm thử cẩn thận để xác định mức độ phù hợp của mô hình.

- Dữ liệu nhiều: Dữ liệu kiểm thử có thể chứa nhiều hoặc các trường hợp đặc biệt không xuất hiện trong dữ liệu huấn luyện. Kiểm thử phải đảm bảo rằng giải pháp học máy có khả năng xử lý các tình huống nhiều và không gặp vấn đề với dữ liệu mới.

2.3.3 Các kỹ thuật và phương pháp kiểm thử phổ biến

- Cross-validation: Phân chia dữ liệu thành các tập huấn luyện và kiểm thử, và thực hiện kiểm thử lặp lại trên các phân chia khác nhau. Điều này giúp đánh giá hiệu suất trung bình của mô hình và giảm thiểu tác động của phân chia dữ liệu ngẫu nhiên.

- Holdout Method: Phân chia dữ liệu thành tập huấn luyện và tập kiểm thử theo tỷ lệ nhất định. Mô hình được huấn luyện trên tập huấn luyện và đánh giá trên tập kiểm thử. Holdout Method đơn giản và nhanh chóng, nhưng có thể dẫn đến ước lượng hiệu suất không chính xác nếu tập kiểm thử quá nhỏ hoặc không đại diện.

- K-fold Cross-validation: Phân chia dữ liệu thành K phần bằng nhau. Mô hình được huấn luyện trên K-1 phần và kiểm tra trên phần còn lại. Quá trình này được lặp lại K lần để đánh giá hiệu suất trung bình của mô hình. K-fold Cross-validation giúp tận dụng tối đa dữ liệu và đánh giá hiệu suất chính xác hơn so với Holdout Method.

2.3.4 Ưu điểm và hạn chế của từng phương pháp kiểm thử

- Cross-validation:

Ưu điểm:

- Tận dụng tối đa dữ liệu: Cross-validation phân chia dữ liệu thành nhiều phần để huấn luyện và kiểm thử. Điều này giúp tận dụng toàn bộ dữ liệu có sẵn trong quá trình kiểm thử.
- Đánh giá hiệu suất tổng quát: Bằng cách lặp lại quá trình kiểm thử trên các phân chia khác nhau, cross-validation cung cấp một ước lượng hiệu suất trung bình của mô hình và giúp đánh giá khả năng tổng quát hóa.

Hạn chế:

- Tính chất khách quan của dữ liệu: Kết quả cross-validation có thể bị ảnh hưởng bởi cách phân chia dữ liệu ngẫu nhiên. Nếu phân chia không đại diện cho dữ liệu thực tế, ước lượng hiệu suất có thể không chính xác.
- Chi phí tính toán: Cross-validation yêu cầu huấn luyện và kiểm thử mô hình nhiều lần, điều này đòi hỏi thời gian và tài nguyên tính toán.

- Holdout Method:

Ưu điểm:

- Đơn giản và nhanh chóng: Holdout Method dễ triển khai và yêu cầu ít thời gian huấn luyện so với cross-validation.
- Đánh giá khả năng tổng quát hóa: Holdout Method chia dữ liệu thành tập huấn luyện và tập kiểm thử, giúp đánh giá hiệu suất trên dữ liệu mới và khả năng tổng quát hóa của mô hình.

Hạn chế:

- Phụ thuộc vào phân chia dữ liệu: Kết quả của Holdout Method có thể bị ảnh hưởng bởi cách phân chia dữ liệu ngẫu nhiên. Nếu tập kiểm thử không đại diện cho dữ liệu thực tế, ước lượng hiệu suất có thể không chính xác.
- Dữ liệu nhỏ hoặc không cân bằng: Nếu tập kiểm thử quá nhỏ hoặc không cân bằng về số lượng các lớp, ước lượng hiệu suất có thể không chính xác.

- K-fold Cross-validation:

Ưu điểm:

- Đánh giá hiệu suất chính xác hơn: K-fold Cross-validation cung cấp một ước lượng hiệu suất trung bình với mức độ tin cậy cao hơn so với Holdout Method.

- Giảm thiểu tác động của phân chia dữ liệu: Bằng cách lặp lại quá trình kiểm thử trên các phân chia khác nhau, K-fold Cross-validation giảm thiểu tác động của việc chọn ngẫu nhiên phân chia dữ liệu.

Hạn chế:

- Chi phí tính toán: K-fold Cross-validation đòi hỏi huấn luyện và kiểm thử mô hình nhiều lần, do đó yêu cầu thời gian và tài nguyên tính toán.
- Dữ liệu không cân bằng: Nếu dữ liệu không cân bằng về số lượng các lớp, K-fold Cross-validation có thể dẫn đến ước lượng hiệu suất không chính xác trên các lớp khác nhau.

- Leave-One-Out Cross-validation:

Ưu điểm:

- Tận dụng tối đa dữ liệu: Leave-One-Out Cross-validation sử dụng tất cả các mẫu trừ một để huấn luyện và kiểm thử. Điều này giúp tận dụng toàn bộ dữ liệu có sẵn trong quá trình kiểm thử.
- Đánh giá chính xác: Với Leave-One-Out Cross-validation, mỗi mẫu được sử dụng một lần làm tập kiểm thử, đảm bảo ước lượng hiệu suất chính xác.

Hạn chế:

- Chi phí tính toán: Leave-One-Out Cross-validation yêu cầu huấn luyện và kiểm thử mô hình nhiều lần bằng số lượng mẫu, do đó đòi hỏi thời gian và tài nguyên tính toán đáng kể.
- Dữ liệu lớn: Trong trường hợp dữ liệu lớn, Leave-One-Out Cross-validation có thể trở nên không khả thi vì số lượng mô hình cần huấn luyện rất lớn.

2.3.5 Tiêu chí và phương pháp đánh giá hiệu suất của một giải pháp học máy

Độ chính xác (Accuracy): Tỷ lệ dự đoán chính xác trên tất cả các điểm dữ liệu. Đây là một phép đo đơn giản và thông thường để đánh giá hiệu suất tổng thể của mô hình, nhưng không phù hợp khi dữ liệu không cân bằng.

Độ phủ (Recall): Tỷ lệ các điểm dữ liệu thuộc lớp dương mà mô hình dự đoán đúng so với tổng số điểm dữ liệu thuộc lớp dương trong dữ liệu thực tế. Độ phủ đánh giá khả năng của mô hình trong việc tìm ra tất cả các trường hợp dương.

Độ chính xác dự đoán (Precision): Tỷ lệ các điểm dữ liệu thuộc lớp dương mà mô hình dự đoán đúng so với tổng số điểm dữ liệu được dự đoán là lớp dương. Độ chính xác dự đoán đánh giá khả năng của mô hình trong việc xác định chính xác các trường hợp dương.

F1-score: Kết hợp giữa độ chính xác và độ phủ thành một phép đo duy nhất. F1-score hỗ trợ đánh giá hiệu suất tổng thể của mô hình trong trường hợp dữ liệu không cân bằng.

ROC-AUC: Đánh giá khả năng phân loại của mô hình dựa trên đường cong ROC (Receiver Operating Characteristic) và diện tích dưới đường cong ROC (Area Under the Curve - AUC). ROC-AUC đo lường khả năng của mô hình phân biệt giữa các lớp dương và âm.

2.3.6 Kết hợp Continual Learning và Test Production

Kết hợp Continual Learning và Test Production trong quá trình xây dựng giải pháp học máy mang lại nhiều lợi ích quan trọng.

Một số lợi ích của việc kết hợp này:

- Tối ưu hóa quá trình Continual Learning: Continual Learning cho phép mô hình học máy tiếp tục học và điều chỉnh sau khi đã được huấn luyện ban đầu. Kết hợp với Test Production, ta có thể tự động tạo ra các bài kiểm tra liên tục để đánh giá hiệu suất của mô hình trong quá trình học. Điều này

giúp cải thiện khả năng tổng quát hóa và phát hiện sớm các vấn đề trong quá trình.

- Đảm bảo tính ổn định và an toàn của hệ thống: Khi áp dụng các cập nhật liên tục vào mô hình, có thể xảy ra hiện tượng quên (forgetting) khi mô hình bỏ qua các kiến thức đã học trước đó. Bằng cách kết hợp Test Production, ta có thể kiểm tra liệu mô hình có đạt được hiệu suất tương tự như trước khi cập nhật hay không. Điều này giúp đảm bảo tính ổn định và an toàn của hệ thống khi thực hiện các cập nhật liên tục.
- Tăng cường khả năng phát hiện sự thay đổi dữ liệu: Khi mô hình đối mặt với sự thay đổi liên tục trong dữ liệu, kết hợp Continual Learning và Test Production giúp phát hiện sớm các sự thay đổi này. Điều này cho phép ta điều chỉnh mô hình kịp thời và duy trì hiệu suất tốt trên dữ liệu mới.

Để kết hợp hiệu quả Continual Learning và Test Production, có thể áp dụng các cách tiếp cận và phương pháp sau:

- Định nghĩa các tiêu chí kiểm tra: Xác định các tiêu chí và chỉ số đánh giá mà ta muốn kiểm tra trong quá trình học liên tục. Ví dụ, có thể đánh giá độ chính xác, độ phân loại, độ đo lỗi, thời gian đáp ứng, v.v.
- Xây dựng bộ kiểm tra tự động: Tạo ra một quy trình tự động để tạo ra các bài kiểm tra liên tục và đánh giá hiệu suất của mô hình. Điều này có thể bao gồm việc sử dụng tập dữ liệu kiểm tra riêng biệt, định nghĩa các phương pháp đánh giá, và thiết kế các quy tắc kiểm tra.
- Sử dụng kỹ thuật Continual Learning: Áp dụng các kỹ thuật Continual Learning như Elastic Weight Consolidation (EWC), Synaptic Intelligence (SI), hoặc Progressive Neural Networks (PNN) để đảm bảo rằng mô hình không quên kiến thức đã học trước đó khi tiếp tục học thêm.
- Cập nhật và kiểm tra định kỳ: Xây dựng lịch trình cập nhật và kiểm tra định kỳ để thực hiện quá trình học liên tục và kiểm tra hiệu suất của mô

hình. Điều này giúp duy trì tính ổn định và đánh giá hiệu quả của mô hình trong quá trình học.

- Sử dụng phương pháp đánh giá đa nhiệm: Kết hợp các bài kiểm tra với nhiều nhiệm vụ khác nhau để đánh giá khả năng tổng quát hóa của mô hình. Điều này giúp mô hình học và điều chỉnh thông qua nhiều loại dữ liệu và tác vụ khác nhau.

2.4 Kết luận

Kết hợp Continual Learning và Test Production trong giải pháp học máy mang lại lợi ích quan trọng như tối ưu hóa học liên tục, đảm bảo tính ổn định và an toàn, và phát hiện sự thay đổi dữ liệu. Đề xuất hướng phát triển tiếp theo bao gồm nghiên cứu kỹ thuật mới, tự động hóa Test Production, đánh giá hiệu suất và tính ổn định, và mở rộng áp dụng vào các lĩnh vực khác nhau.

TÀI LIỆU THAM KHẢO

<https://viblo.asia/p/optimizer-hieu-sau-ve-cac-thuat-toan-toi-uu-gdsgdadam-Qbq5QQ9E5D8?fbclid=IwAR1v2fWF55VJHaRkh1eRpIBmYov92XOr0dpQAWelMZgWV8J1Ia4GMOPASQw>

https://machinelearningcoban.com/2017/01/16/gradientdescent2/?fbclid=IwAR3YO_uPCi53xSMo6YRW_y6a1oF4QAKF6sUFfblsCA-N_Qc_jnKCjhja3i4

https://machinelearningcoban.com/2017/01/12/gradientdescent/?fbclid=IwAR0DVC2QkW3c7z4aJgO3goSPumvzfCN9UHA3h97CAR_W0-IZS32nrzJioNA